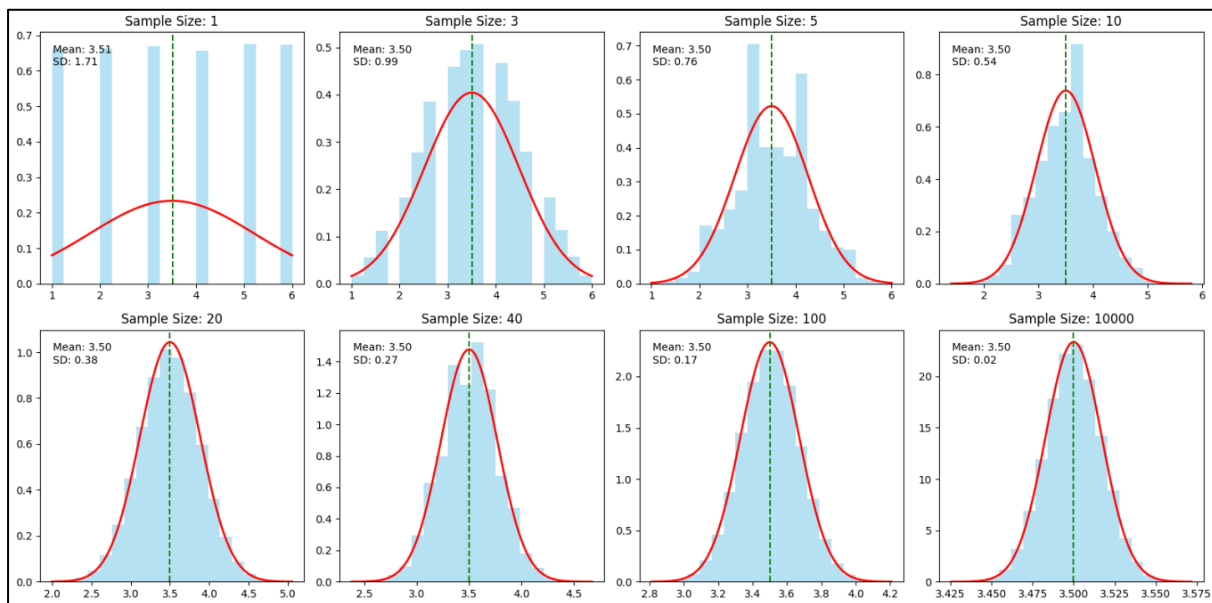


## การพิสูจน์: ทฤษฎีแนวมัวเข้าสู่ส่วนกลาง (The Central Limit Theorem)

ทฤษฎีแนวมัวเข้าสู่ส่วนกลาง (The Central Limit Theorem; CLT) กล่าวว่า

สำหรับประชากรใด ๆ แล้ว หากเราเก็บตัวอย่างในจำนวนที่มากพอ การกระจายของค่าเฉลี่ยตัวอย่างดังกล่าวจะมีแนวมัวใกล้เคียงกับการกระจายแบบปกติ (Normal distribution) เสมอ โดยไม่คำนึงถึงรูปร่างการกระจายที่แท้จริงของประชากรนั้น

สรุปโดยย่อ ถ้าเราสุ่มตัวอย่างซ้ำเรื่อย ๆ และบันทึกค่าเฉลี่ยที่ได้จากการสุ่มตัวอย่างแต่ละครั้ง แล้วนำค่าเหล่านั้นมาสร้างแผนภูมิฮิสโตแกรม (Histogram) จะได้ว่าข้อมูลมีการแจกแจงแบบปกตินั่นเอง



ตัวอย่าง CLT โดยให้  $X$  แทนค่าเฉลี่ยของหมายเลขที่เกิดจากการทอยลูกเต๋า 6 หน้าเพียงตรง

ที่มา: [Statistics-and-ML/Central\\_Limit\\_Theorem.ipynb at main · SKY-TKP/Statistics-and-ML](#)

### ประเด็นสำคัญ

- ทฤษฎีบทนี้ระบุถึงความสำคัญที่ว่า การกระจายของค่าเฉลี่ยตัวอย่างจะใกล้เคียงกับการแจกแจงปกติเมื่อตัวอย่างมีขนาดใหญ่โดยไม่คำนึงถึงการแจกแจงของประชากรที่แท้จริง
- การสุ่มตัวอย่างต้องเป็นไปอย่างสุ่ม (Random Sampling)
- เราจะเรียก ค่าเฉลี่ยจากการสุ่มตัวอย่างเหล่านั้นว่า “ค่าเฉลี่ยกลุ่มตัวอย่าง (Sample Mean;  $\bar{x}$ )” และเรียก ส่วนเบี่ยงเบนมาตรฐานของค่าเฉลี่ยเหล่านั้นว่า “ส่วนเบี่ยงเบนมาตรฐานของค่าเฉลี่ยกลุ่มตัวอย่าง (Sample Standard Deviation;  $s_{\bar{x}}$ )”

## ทบทวนคณิตศาสตร์ที่จำเป็น

### [1] ตัวแปรสุ่ม (Random Variable) และคุณสมบัติพื้นฐาน

ตัวแปรสุ่ม  $X$  คือ ฟังก์ชันจากปริภูมิตัวอย่างของการทดลองสุ่ม ( $S$ ) ไปยัง เซตของจำนวนจริง ( $\mathbb{R}$ )

$$X: S \rightarrow \mathbb{R}$$

โดยที่

- $E[X] =$  ค่าเฉลี่ยของตัวแปรสุ่ม  $= \frac{\sum_i x_i}{N}$
- $Var[X] =$  ความแปรปรวนของตัวแปรสุ่ม  $= \frac{\sum_i x_i^2 - \mu^2}{N}$

### [2] ฟังก์ชันความหนาแน่นความน่าจะเป็นของการแจกแจงปกติ (Probability Density Func.)

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

เมื่อ  $\mu = E[X]$  และ  $\sigma = \sqrt{Var[X]}$

เขียนแทนด้วย  $X \sim Normal(\mu, \sigma^2)$

หมายเหตุ: เมื่อ  $\mu = 0$  และ  $\sigma = 1$  เราจะเรียกการแจกแจงดังกล่าวเป็น การแจกแจงปกติมาตรฐาน

(Standard Normal Distribution)

### [3] ฟังก์ชันก่อกำเนิดโมเมนต์ (Moment Generating Function; MGF)

$$M_X(t) = E[e^{tx}] = \int_{-\infty}^{\infty} e^{tx} f(x) dx$$

โดยที่

- เมื่อ  $Z$  เป็นตัวแปรสุ่มที่มีการแจกแจงปกติมาตรฐาน จะได้ว่า

$$M_Z(t) = E[e^{tx}] = \int_{-\infty}^{\infty} e^{tz} \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} dz = e^{\frac{t^2}{2}}$$

- $M_X^{(n)}(t) = 0 = \int_{-\infty}^{\infty} x^n f(x) dx$
- ถ้า  $X$  และ  $Y$  เป็นตัวแปรสุ่มที่เป็นอิสระต่อกันแล้ว จะได้ว่า  $M_{X+Y}(t) = M_X(t) M_Y(t)$
- ถ้า  $X$  และ  $Y$  มีฟังก์ชันก่อกำเนิดโมเมนต์เดียวกันแล้ว  $X$  และ  $Y$  มีการแจกแจงเดียวกัน

$$M_X(t) = M_Y(t) ; \forall t \in \mathbb{R} \implies X, Y \text{ are same distribution.}$$

### [4] เพิ่มเติม

- นิยามของเลขออยเลอร์ (Euler's number;  $e$ )

$$\lim_{n \rightarrow \infty} \left(1 + \frac{k}{n}\right)^n = e^k$$

- อนุกรมเทย์เลอร์ของฟังก์ชันเลขชี้กำลัง (Taylor's series of exponential function)

$$e^x = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \dots = \sum_{n=0}^{\infty} \frac{x^n}{n!}$$

## ขั้นตอนการพิสูจน์

ข้อกำหนด: <sup>1</sup>

- [1] พิจารณาจากตัวแปรสุ่ม  $X$  ที่มีการกระจายแบบหนึ่ง ๆ (ที่เราไม่รู้) โดยมี  $\mu_X = \mu = E[X]$  และ  $\sigma_X^2 = Var[X]$
- [2] การเลือกตัวอย่างของเราจากค่าที่เป็นไปได้ทั้งหมดในตัวแปรสุ่ม  $X$  จะต้องมีความสมบัติต่อไปนี้
- (2.1) การเลือกตัวอย่างแบบสุ่ม
  - (2.2) การสุ่มแต่ละครั้งต้องเป็นอิสระต่อกัน
  - (2.3) การสุ่มแต่ละครั้งต้องมาจากประชากรในการแจกแจงเดิม
- [3] จากผลของ [2] เขียนรวบรัดเป็น  $X_i$  เป็น *i. i. d. independent and identically distributed* โดย  $X_i$  คือ ตัวแปรสุ่มของค่าที่เป็นไปได้จากปริภูมิตัวอย่างในทั้งหมดในตัวแปรสุ่ม  $X$  ตัวที่  $i = 1, 2, 3, \dots, n$  จากการสุ่มมา  $n$  ครั้ง
- [4] การสุ่มตัวอย่าง ควรใช้ขนาดกลุ่มตัวอย่าง  $n$  จำนวนมาก ๆ

การพิสูจน์:

[1] กำหนดให้  $Y_n = \frac{1}{n} (X_1 + X_2 + X_3 + \dots + X_n) = \frac{1}{n} \sum_{i=1}^n X_i$

ดังนั้น

เราบอกได้ว่า  $Y_n$  คือ ตัวแปรสุ่มที่แทนค่าเฉลี่ยกลุ่มตัวอย่างจากการสุ่มในประชากร  $X$  จะได้ว่า

$$\begin{aligned} E[Y_n] &= E \left[ \frac{1}{n} \sum_{i=1}^n X_i \right] = \frac{1}{n} [ E[X_1] + E[X_2] + \dots + E[X_n] ] \\ &= \frac{1}{n} \mu + \mu + \dots + \mu \\ &= \frac{1}{n} n\mu = \mu \dots (1.1) \end{aligned}$$

$$\begin{aligned} Var[Y_n] &= Var \left[ \frac{1}{n} \sum_{i=1}^n X_i \right] \\ &= \frac{1}{n^2} \left[ Var[X_1] + Var[X_2] + \dots + Var[X_n] + \sum_i \sum_{i \neq j} Cov(X_i, X_j) \right] \end{aligned}$$

จาก ข้อกำหนด (2.2) ทำให้  $Cov(X_i, X_j) = 0$ ;

$$Var[Y_n] = \frac{1}{n^2} [ \sigma^2 + \sigma^2 + \dots + \sigma^2 ] = \frac{1}{n^2} n\sigma^2 = \frac{\sigma_X^2}{n} \dots (1.2)$$

<sup>1</sup> ด้วยข้อกำหนดที่จะนำไปสู่การพิสูจน์เหล่านี้จึงเป็นสิ่งสืบเนื่องที่ต้องตรวจสอบเสมอ  
หลังทำการใช้สถิติเชิงอนุมานในหลาย ๆ ส่วน

จากข้อ [1]

- เมื่อเราสุ่มตัวอย่างจากประชากร  $X$  แล้วนำมาหาค่าเฉลี่ย เราเชื่อว่าค่าเฉลี่ยของกลุ่มตัวอย่างที่ได้มานั้นมีโอกาสเป็นค่าเฉลี่ยที่แท้จริงของประชากรดังกล่าว ในขณะที่ถ้าหาความแปรปรวนแทนจะกลายเป็น ความแปรปรวนของประชากรหารขนาดกลุ่มตัวอย่างที่เราเลือกมาสุ่ม
- $E[Y_n] = x_n = \mu =$  ค่าเฉลี่ยกลุ่มตัวอย่างจากการสุ่มในตัวแปรสุ่ม  $X$
- $Var[Y_n] = s_n^2 = \sigma_X^2/n =$  ความแปรปรวนตัวอย่างจากการสุ่มในตัวแปรสุ่ม  $X^2$

[2] กำหนดให้

$$Z_n = (Y_n - \mu)/s_x$$

$$= \frac{\sqrt{n}}{\sigma_X} \left( \frac{1}{n} \sum_{i=1}^n X_i - \mu \right)$$

$$= \frac{1}{\sqrt{n}} \sum_{i=1}^n \left( \frac{X_i - \mu}{\sigma_X} \right)$$

$$Z_n = \frac{1}{\sqrt{n}} \sum_{i=1}^n S_i \quad \text{โดย} \quad S_i = \frac{X_i - \mu}{\sigma_X}$$

$$\text{ทั้งนี้ } E[S_i] = \frac{1}{\sigma_X} E[X_i - \mu] = 0$$

$$Var[S_i] = \left( \frac{1}{\sigma_X} \right)^2 Var[X_i] - Var[\mu] = 1$$

$$\text{และ } E[Z_n] = \frac{1}{\sqrt{n}} \sum_{i=1}^n E[S_i] = 0$$

$$Var[Z_n] = \left( \frac{1}{\sqrt{n}} \right)^2 \sum_{i=1}^n Var[S_i] = 1 = E[Z^2] - E[Z]^2 = E[Z^2]$$

---

<sup>2</sup> ภายหลัง เรามีอีกชื่อให้เป็น Standard Error ของตัวแปรสุ่ม  $X$  จากการสุ่มตัวอย่างขนาด  $n$

[3] พิสูจน์ว่า

$$\begin{aligned}
 M_{Z_n}(t) &= M_{\sum_{i=1}^n S_i}(t/\sqrt{n}) \\
 &= M_{S_1+S_2+\dots+S_n}(t) \\
 &= M_{S_1}\left(\frac{t}{\sqrt{n}}\right) M_{S_2}\left(\frac{t}{\sqrt{n}}\right) \dots M_{S_n}\left(\frac{t}{\sqrt{n}}\right) \quad \because S_i \text{ เป็นอิสระต่อกัน} \\
 &= \left[ M_{S_n}\left(\frac{t}{\sqrt{n}}\right) \right]^n
 \end{aligned}$$

สนใจที่พจน์  $M_{S_n}(t)$

$$\begin{aligned}
 M_{S_n}(t) &= M_{(X_i-\mu)}(t) \\
 &= E[e^{t(X_i-\mu)}] \\
 &= E\left[1 + t(X_i - \mu) + \frac{t^2(X_i - \mu)^2}{2!} + \dots + \frac{t^n(X_i - \mu)^n}{n!}\right] \\
 &= 1 + tE[X_i - \mu] \\
 &\quad + \frac{t^2}{2!} [E[X_i - \mu]^2] - E[X_i - \mu] + E[X_i - \mu] \quad \because E[X_i - \mu] = 0 \\
 &\quad + \frac{t^3(X_i - \mu)^3}{3!} \dots + \frac{t^n(X_i - \mu)^n}{n!} \\
 &= 1 + \frac{t^2}{2!} + \frac{t^3(X_i - \mu)^3}{3!} \dots + \frac{t^n(X_i - \mu)^n}{n!}
 \end{aligned}$$

เพราะฉะนั้น

$$M_{Z_n}(t) = \left[ 1 + \frac{(t/\sqrt{n})^2}{2!} + \frac{(t/\sqrt{n})^3(X_i - \mu)^3}{3!} \dots + \frac{(t/\sqrt{n})^n(X_i - \mu)^n}{n!} \right]^n$$

ทำการ Take ln;

$$\ln[M_{Z_n} t] = n \cdot \ln \left[ 1 + \frac{(t/\sqrt{n})^2}{2!} + \frac{(t/\sqrt{n})^3 X_i - \mu^3}{3!} \dots + \frac{(t/\sqrt{n})^n X_i - \mu^n}{n!} \right]$$

เนื่องจากเทอมฝั่งขวาของสมการสามารถเขียนในรูปอนุกรมแมคลอริน ได้เป็น

$$\ln(1 + x) = \sum_{n=1}^{\infty} \frac{-1^{n+1}}{n} x^n$$

จึงได้เป็น

$$\ln[M_{Z_n} t] = n \cdot \sum_{k=1}^{\infty} \frac{-1^{k+1}}{k} \left( \frac{(t/\sqrt{n})^2}{2!} + \frac{(t/\sqrt{n})^3 X_i - \mu^3}{3!} \dots + \frac{(t/\sqrt{n})^n X_i - \mu^n}{n!} \right)^k$$

แยกอนุกรมออกเป็น 2 ส่วน คือ k = 1 และ 2 เป็นต้นไป

$$\ln[M_{Z_n} t] = n \cdot \left[ \left( \frac{(t/\sqrt{n})^2}{2!} + \frac{(t/\sqrt{n})^3 X_i - \mu^3}{3!} \dots + \frac{(t/\sqrt{n})^n X_i - \mu^n}{n!} \right) + \sum_{k=2}^{\infty} \frac{-1^{k+1}}{k} \left( \frac{(t/\sqrt{n})^2}{2!} + \frac{(t/\sqrt{n})^3 X_i - \mu^3}{3!} \dots + \frac{(t/\sqrt{n})^n X_i - \mu^n}{n!} \right)^k \right]$$

กระจายพจน์ n ออกสุดไปในวงเล็บใหญ่

$$\ln[M_{Z_n} t] = \left( \frac{t^2}{2!} + \frac{n(t)^3 X_i - \mu^3}{3! n^{3/2}} \dots + \frac{n(t)^n X_i - \mu^n}{n! n^{n/2}} \right) + \sum_{k=2}^{\infty} \frac{-1^{k+1}}{k} \left( \frac{t^2}{2!} + \frac{n(t)^3 X_i - \mu^3}{3! n^{3/2}} \dots + \frac{n(t)^n X_i - \mu^n}{n! n^{n/2}} \right)^k$$

พิจารณาที่  $n \rightarrow \infty$

$$\begin{aligned} \lim_{n \rightarrow \infty} \ln[M_{Z_n} t] &= \lim_{n \rightarrow \infty} \left( \frac{t^2}{2!} + \frac{n t^3 X_i - \mu^3}{3! n^2} \dots + \frac{n t^n X_i - \mu^n}{n! n^{\frac{n}{2}}} \right) \\ &+ \lim_{n \rightarrow \infty} \sum_{k=2}^{\infty} \frac{-1^{k+1}}{k} \left( \frac{t^2}{2!} + \frac{n(t)^3 X_i - \mu^3}{3! n^{3/2}} \dots + \frac{n(t)^n X_i - \mu^n}{n! n^{n/2}} \right)^k \\ &= \frac{t^2}{2} \dots \blacksquare \end{aligned}$$

เพราะฉะนั้น

$$M_{Z_n}(t) = e^{\frac{t^2}{2}}$$

[4]. เนื่องจาก  $M_{Z_n}(t)$  มี MGF. เดียวกับ MGF ของการแจกแจงปกติมาตรฐาน

เพราะฉะนั้น  $Z_n \sim \text{Normal } 0, 1$

กล่าวคือ  $\frac{Y_n - \mu}{s_x}$  หรือตัวแปรสุ่มค่าเฉลี่ยกลุ่มตัวอย่างนี้มีการแจกแจงปกติมาตรฐาน

[5]. จากข้อ [4]. ดังนั้น

การแจกแจงของค่าเฉลี่ยตัวอย่างที่มีการแจกแจงปกติ